

Inżynieria Uczenia Maszynowego

Studenci:

Bartłomiej Krawczyk
Mateusz Brzozowski

Temat

“Jakiś czas temu wprowadziliśmy konta premium, które uwalniają użytkowników od słuchania reklam. Nie są one jednak jeszcze zbyt popularne – czy możemy się dowiedzieć, które osoby są bardziej skłonne do zakupu takiego konta?”

Szczegółowy opis tematu

W ramach projektu wcielamy się w rolę analityka pracującego dla portalu „Pozytywka” - serwisu muzycznego, który swoim użytkownikom pozwala na odtwarzanie ulubionych utworów online. Praca na tym stanowisku nie jest łatwa - zadanie dostajemy w formie enigmatycznego opisu i to do nas należy doprecyzowanie szczegółów tak, aby dało się je zrealizować. To oczywiście wymaga zrozumienia problemu, przeanalizowania danych, czasami negocjacji z szefostwem. Same modele musimy skonstruować tak, aby gotowe były do wdrożenia produkcyjnego - pamiętając, że w przyszłości będą pojawiać się kolejne ich wersje, z którymi będziemy eksperymentować.

Jak każda szanująca się firma internetowa, Pozytywka zbiera dane dotyczące swojej działalności - są to:

- lista dostępnych artystów i utworów muzycznych,
- baza użytkowników,
- historia sesji użytkowników,
- techniczne informacje dot. poziomu cache dla poszczególnych utworów.

(analitycy mogą wnioskować o dostęp do tych informacji na potrzeby realizacji zadania)

Problem biznesowy

Określenie celu biznesowego

Opis kontekstu

Portal "Pozytywka" oferuje użytkownikom możliwość odtwarzania ulubionych utworów online, zarówno w wersji darmowej, jak i wersji premium. Firma chce przekonać użytkowników, że warto płacić za konto premium i zwiększyć liczbę osób, które decydują się na zakup takiego konta. Aby zachęcić użytkowników do zakupu konta premium, niezbędne są dane dotyczące ich skłonności do wykonywania tej akcji. Pozwolą one na precyzyjne dostosowanie działań marketingowych.

Zdefiniowanie celów biznesowych.

Celem biznesowym jest zwiększenie liczby użytkowników korzystających z konta premium, co przyczyni się do zwiększenia przychodów serwisu "Pozytywka". Chcemy stworzyć model, który pozwoli nam na przewidywanie, którzy użytkownicy są bardziej skłonni do zakupu konta premium, aby móc ich nakłonić do zakupu. Model powinien działać na bieżąco, a jego wyniki powinny być użyte do podejmowania decyzji biznesowych, takich jak targetowanie reklam odtwarzanych użytkownikom non-premium.

Biznesowe kryterium sukcesu.

Eksperymenty A/B: Co miesiąc system będzie przydzielał użytkowników do dwóch różnych podgrup (grupy kontrolnej i grupy doświadczalnej). Każdy użytkownik po otrzymaniu przydziału pozostanie w nim dożywotnio, bez możliwości zmienienia przydziału. Podziału takie dokonamy stosując funkcję hasującą modulo w zależności od procentowego podziału na grupy, następnie przypisując odpowiedni identyfikator grupy do konkretnego użytkownika.

Posiadamy dwie grupy dla każdego miesiąca: grupę kontrolną, korzystającą z portalu w sposób niezmienny oraz grupę doświadczalną, korzysta z portalu, ale z zastosowaniem naszego modelu.

Co miesiąc dokonujemy weryfikacji procentowego podziału użytkowników, na tych którzy posiadają premium oraz osób bez premium, osobno dla każdej grupy kontrolnej i doświadczalnej. Następnie porównujemy wyniki dla kolejnych miesięcy, która z grup (kontrolna/ doświadczalna) poradziła sobie lepiej.

Prowadzenie takich statystyk pozwoli nam ocenić jak bardzo opłacalny jest nasz model, jednakże takowe wnioski będziemy mogli wyciągnąć, dopiero w dłuższej perspektywie czasu.

Interwencja Dla każdego użytkownika non-premium korzystającego z naszej platformy wyliczamy wymagane cechy i na podstawie tego generujemy predykcję.

Na ten moment, nie jesteśmy w stanie przewidzieć w jaki sposób zostaną wykorzystane nasze predykcje. Wobec tego, proponujemy kilka podejść:

Pierwsze, sprawdzające jak dzięki naszym predykcjom pozytywka będzie mogła modyfikować zachowanie ich platformy, tak aby dopasować się do danych wynikających z metody XAI np. częściej puszczać utwory, które są popularne.

Drugie, wykorzystujący np. algorytm genetyczny, tworzący symulację i sprawdzający jak zmiana poszczególnych cech danego użytkownika (oczywiście tych, które możemy wpływać) oddziałuje na jego predykcje, dzięki czemu będziemy mogli symulować możliwe wyniki, nie czekając na wyniki obserwacji zachowań modelu w środowisku realnym. Sprawi to, że najlepsze wyniki symulacji, będziemy mogli wykorzystać w modelu znajdującym się w środowisku rzeczywistym.

Określenie celów modelowania.

Opis zadań modelowania.

W ramach tego zadania analitycznego zajmujemy się **klasyfikacją binarną** użytkowników portalu "Pozytywka" na podstawie danych zebranych w pewnym okresie. Naszym celem jest określenie, czy dany użytkownik kupi konto premium, czy nie. W pierwszej kolejności dokonujemy agregacji tych danych i tworzymy z nich wektory cech dla każdego użytkownika. Następnie wykorzystujemy różne modele klasyfikacyjne, takie jak np. regresja logistyczna czy drzewa decyzyjne, aby przewidzieć, czy użytkownik kupi konto premium, czy też nie.

Definicja kryteriów sukcesu z perspektywy analitycznej.

Analityczne kryterium sukcesu będzie wyznaczane na podstawie danych dostarczonych przez klienta (danych offline), tak abyśmy mogli zweryfikować nasz model przed wdrożeniem. Wśród wszystkich użytkowników, których otrzymaliśmy, około 50% to użytkownicy premium. Po usunięciu sesji użytkowników premium procent miesięcznych sesji użytkowników, o których mamy informację, że kiedykolwiek kupią premium wynosi 25%. Natomiast procent miesięcznych sesji użytkowników, o których mamy informację, że kupią w przeciągu 30 dni premium wynosi 2%. Oznacza to, że jeżeli skorzystalibyśmy z naiwnego klasyfikatora, który przypisywał by wszystkim grupę większościową, to otrzymalibyśmy odpowiednio 75% i 98% skuteczności. Tak więc naszym analitycznym kryterium sukcesu będzie poprawa tego wyniku. Dodatkowo będziemy w stanie wyjaśnić, z czego wynika przekonanie.

Ocena aktualnej sytuacji.

Spis dostępnych zasobów.

- Lista dostępnych artystów i utworów muzycznych.
- Baza 20 tys. użytkowników z 50 tys. wszystkich osób korzystających z platformy
- Historia sesji użytkowników.
- Techniczne informacje dotyczące poziomu cache dla poszczególnych utworów.

Założenia:

- Kupiona usługa premium jest trwała i nie ma potrzeby jej ponownego zakupu.
- Polubienie piosenek jest jednorazowe i utrzymuje się przez cały okres użytkowania platformy.
- Dane są agregowane dla miesięcznych okien czasowych.
- Użytkownicy, którzy nie posiadają konta premium, mają zazwyczaj mniejszy stosunek czasu słuchania muzyki do czasu odtwarzania reklam niż użytkownicy posiadający konto premium. W związku z tym, jeśli bierzemy pod uwagę sesje użytkowników, którzy już zakupili premium, mogłoby to wpłynąć na wyniki modelu i sugerować zmniejszenie ilości odtwarzanych reklam tylko po to, aby użytkownicy zdecydowali się na zakup konta premium. Aby uniknąć takiej sytuacji, sesje użytkowników, którzy już zakupili konto premium, nie będą brane pod uwagę w procesie trenowania modelu klasyfikacji.
- Nie ma ograniczeń na ilość reklam, które można wyświetlić w danym czasie, ponieważ platforma może sama reklamować swoje usługi premium.

Ograniczenia:

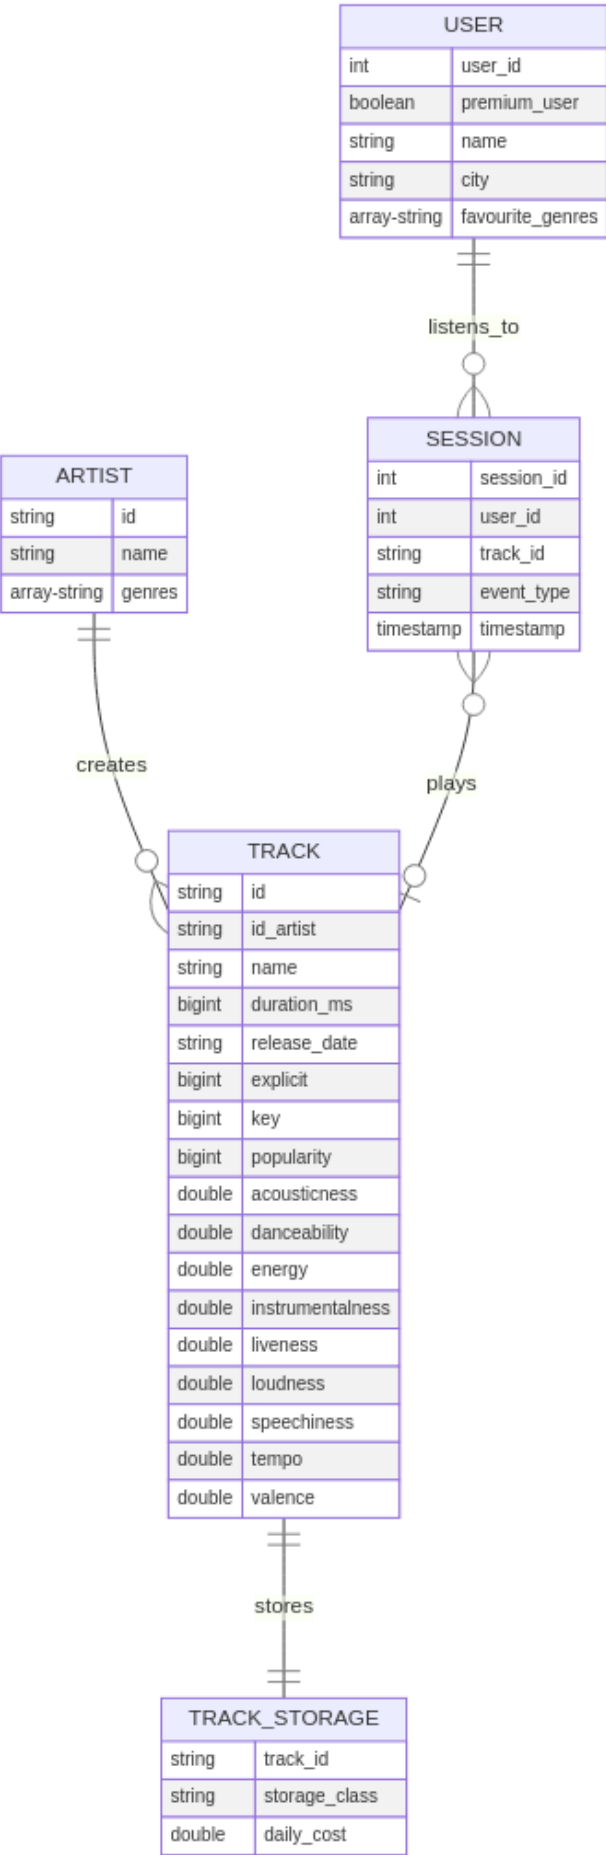
- Posiadamy dane dotyczące tylko 40% użytkowników korzystających z platformy.
- Posiadamy dane z sesji sprzed 3 lat.

- Model klasyfikacji opiera się tylko na danych zgromadzonych wewnątrz platformy, nie uwzględniając zewnętrznych czynników wpływających na decyzje użytkowników.
- Działamy tylko na historii danych dostępnych do końca danego okresu.

Wstępne propozycje narzędzi i metod.

- Python - Język programowania.
- Spark - Dostarcza prosty sql'owy dostęp, co ułatwia pracę z dużymi zbiorami danych.
- Pandas - Biblioteka Pythona do manipulacji i analizy danych. Umożliwia łatwe wczytywanie danych z różnych źródeł, manipulowanie nimi oraz przeprowadzanie analizy danych.
- Scikit-learn (sklearn) - Biblioteka Pythona udostępniająca wiele algorytmów uczenia maszynowego, a także narzędzia do oceny modeli.
- XAI: Explainable AI - W kolejnym etapie będziemy chcieli skupić się na wyjaśnieniu, dlaczego użytkownik chce zakupić premium i czy jesteśmy w stanie przekonać go do takiej decyzji.

Analiza Danych



Informacje od klienta:

- System oferuje tylko jedną ofertę konta premium
- Konta premium nie można dzielić
- System obsługuje obecnie ok. 50 tys. użytkowników
- Reklamy zmieniają się w zależności od konkretnych umów z innymi podmiotami. Za dobór częstotliwości reklam odpowiada nasz autorski algorytm.
- Dane dostępne są w formacie plików JSON.
- Dane są uwspólnione, a ew. różnice wynikające ze sposobu ich zbierania zostały usunięte.
- Nie posiadamy takiego systemu, który stara się przewidzieć kto jest skłonny do zakupu konta premium
- Klient jest naszym ekspertem domenowym

Dane V1

Quality Report V1

Błędy w danych:

- W kolumnach znajduje się dużo identyfikatorów o "id": -1.
- W pliku sessions.jsonl mamy null'e w kolumnie "user_id"
- Favourite_genres zawiera rekordy null
- "premium_user" zawiera rekordy null. W tej kolumnie nie widzimy wartości false.
- 5 użytkowników ma pole o nazwie "id"
- W sessions, user_id oraz track_id są nullami, szczególnie gdy event_type jest ustawione na ADVERTISEMENT lub BUY_PREMIUM.
- event_type zawiera rekordy null
- Tylko 4 rekordy dla przypadku "FAST"
- W tracks, acousticness, danceability, speechiness, tempo, valence, energy są zerami
- W tracks kolumny id, id_artists zawierają nulle
- W sessions jest mało rekordów zawierających wystąpienia pól ADVERTISEMENT i BUY_PREMIUM
- Dane z krótkiego okresu działania funkcji PREMIUM
- Średnia głośność (loudness) w decybelach, typowo od -60 do 0dB, dane posiadają zakres od -60 do 4.8 dB.

Wnioski wyciągnięte na podstawie danych, a także informacje dostarczone przez klienta:

- Posiadamy dostęp do danych ok. 20k użytkowników
- Reklamy są przechowywane w chmurze.
- Kolumna key: liczby w https://en.wikipedia.org/wiki/Pitch_class
- Kolumna instrumentalness: przewidywanie czy utwór posiada wokal, im bliżej 1.0 tym wyższe prawdopodobieństwo, że utwór jest instrumentalny. Wartości powyżej 0.5 można traktować jak utwory instrumentalne
- Przewidzenie czy dany użytkownik jest skłonny do zakupu takiego konta
- Możecie Państwo sami ustalić format danych przyjmowanych/odsyłanych
- Określenie przynależności danego użytkownika

Dane V2

Quality Report V2

Wnioski wyciągnięte na podstawie danych, a także informacje dostarczone przez klienta:

- BUY_PREMIUM jest dożywotnie
- polubienie piosenki jest jednorazowe i dożywotnie
- nie mamy informacji o gatunkach per utwór, tak więc zakładamy, że jeśli dany artysta tworzy muzykę w danym gatunku, to jego wszystkie utwory należą do tych samych gatunków
- System pozwala dodać piosenki o takiej samej nazwie
- System pozwala założyć konta artystom o tej samej nazwie
- Artyści mogą maksymalnie wstawiać utwory o długości trwania poniżej 2h
- release_date jest czasami datą w formacie YYYY-MM-DD, a czasami YYYY
- instrumentalness równe 0.0 w 46190 przypadków i oznacza, że algorytm jest pewny, że piosenka zawiera wokal
- w popularity występuje pik w 0.0, większość piosenek nie jest zbyt popularna
- track_id = " w przypadku reklam (1288318 przypadków) oznacza, że reklama pochodzi z chmury i nie mamy informacji o tej reklamie
- 118940 utworów muzycznych nigdy nie było odsłuchane, są mało popularne
- na potrzeby tego projektu użytkownicy są jedynie z największych miast w polsce?

- W tabeli artyści zdefiniowanych jest 3912 unikalnych gatunków muzyki, a wśród udostępnionych użytkowników występuje jedynie 50 z tych gatunków. Dla wielu z gatunków mamy tak mało danych, że preferujemy skupić się na najbardziej popularnych gatunkach muzycznych

Błędy w danych:

- Występuje 41 rekordów loudness o wartościach większych niż 0.0.
- tempo równe 0.0 w 48 przypadkach

```
import pandas as pd
import os
from IPython.display import display
```

Wstępny zbiór treningowy

Na ten moment mamy przygotowane dwie kolumny pomagające określić to jakie mogą być zamiary użytkownika, na podstawie miesiąca:

Pierwsza `premium_user_numerical` mówiąca nam, czy użytkownik kiedykolwiek kupi premium oraz druga `will_buy_premium_next_month` przedstawiająca to czy użytkownik zakupi premium w przeciągu następnych 30 dni.

Przygotowaliśmy różne cechy naszych danych, na podstawie których postaramy się sklasyfikować użytkowników:

- `number_of_advertisements`, ilość odtworzonych reklam w danym miesiącu
- `number_of_tracks`, ilość przesłuchanych utworów w danym miesiącu
- `number_of_skips`, ilość pominiętych utworów w danym miesiącu
- `number_of_likes`, liczba danych lików w danym miesiącu
- `number_of_liked_tracks_listened`, liczba przesłuchanych utworów w danym miesiącu, które w momencie odtworzenia były polubione
- `number_of_tracks_in_favourite_genre`, liczba przesłuchanych utworów z ulubionego gatunku u danym miesiącu
- `total_number_of_favourite_genres_listened`, liczba przesłuchanych gatunków w danym miesiącu należących do twoich ulubionych
- `average_popularity_in_favourite_genres`, średnia popularność utworów wśród ulubionych gatunków w danym miesiącu
- `total_tracks_duration_ms`, całkowity czas przesłuchanych utworów w danym miesiącu
- `number_of_different_artists`, ilość przesłuchanych artystów w danym miesiącu
- `average_release_date`, średnia data przesłuchanych piosenek w danym miesiącu
- `average_duration_ms`, średni czas trwania utworów przesłuchanych w danym miesiącu
- `explicit_tracks_ratio`, średnia ilość "wulgarnych" utworów przesłuchanych w danym miesiącu
- `average_popularity`, średnia popularność przesłuchanych utworów w danym miesiącu
- `average_acousticness`, średnia akustyka przesłuchanych utworów w danym miesiącu
- `average_danceability`, średnia taneczność przesłuchanych utworów w danym miesiącu
- `average_energy`, średnia moc przesłuchanych utworów w danym miesiącu
- `average_instrumentalness`, średnia ilość utworów z wokalem przesłuchanych w danym miesiącu
- `average_liveness`, średnie brzmienie utworów na żywo przesłuchanych w danym miesiącu
- `average_loudness`, średnia głośność przesłuchanych utworów w danym miesiącu
- `average_speechiness`, średnia ilość wokalu w utworach przesłuchanych w danym miesiącu
- `average_tempo`, średnia prędkość przesłuchanych utworów w danym miesiącu
- `average_valence`, średnia emocjonalność przesłuchanych utworów w danym miesiącu
- `average_track_name_length`, średnia długość nazwy utworów przesłuchanych w danym miesiącu
- `average_daily_cost`, średni koszt utrzymania przesłuchanych piosenek w danym miesiącu

Wyżej wymienione cechy, a także ich implementacja znajdują się w folderze `features`, tam też znajduje się wyniki.

```
FEATURE_VERSION = 'v1'

TARGET = [
    "premium_user_numerical",
    "will_buy_premium_next_month_numerical"
]

FEATURES = [
    'number_of_advertisements',
    'number_of_tracks',
    'number_of_skips',
    'number_of_likes',
```

```

'number_of_liked_tracks_listened',
'number_of_tracks_in_favourite_genre',
'total_number_of_favourite_genres_listened',
'average_popularity_in_favourite_genres',
'total_tracks_duration_ms',
'number_of_different_artists',
'average_release_date',
'average_duration_ms',
'explicit_tracks_ratio',
'average_popularity',
'average_acousticness',
'average_danceability',
'average_energy',
'average_instrumentalness',
'average_liveness',
'average_loudness',
'average_speechiness',
'average_tempo',
'average_valence',
'average_track_name_length',
'average_daily_cost'
]

```

```

feature_path = os.path.join('features', FEATURE_VERSION, 'feature.csv')
dataframe = pd.read_csv(feature_path)

```

Przykładowe wartości cech i targetów

```
display(dataframe)
```

	user_id	year	month	premium_user_numerical \
0	212	2020	2	1
1	212	2020	7	1
2	212	2020	1	1
3	212	2020	3	1
4	212	2020	8	1
...
182383	5243	2020	2	1
182384	17786	2020	2	0
182385	16683	2020	1	0
182386	18570	2019	11	0
182387	15795	2021	9	0

	will_buy_premium_next_month_numerical	number_of_premium \
0	0	0
1	0	0
2	0	0
3	0	0
4	0	0
...
182383	0	0
182384	0	0
182385	0	0
182386	0	0
182387	0	0

	number_of_advertisements	number_of_tracks	number_of_skips \
0	10	30	16
1	5	16	8
2	14	39	21
3	3	20	9

4	13	40	22
...
182383	0	1	1
182384	0	5	0
182385	0	5	0
182386	0	5	0
182387	1	6	1

	number_of_likes	...	average_danceability	average_energy	\
0	8	...	0.542767	0.600467	
1	2	...	0.499000	0.675250	
2	12	...	0.487000	0.691667	
3	6	...	0.516700	0.637150	
4	12	...	0.513525	0.642350	
...	
182383	1	...	0.572000	0.267000	
182384	3	...	0.646000	0.566200	
182385	1	...	0.632200	0.572200	
182386	0	...	0.681800	0.506400	
182387	1	...	0.640000	0.638667	

	average_instrumentalness	average_liveness	average_loudness	\
0	0.094653	0.179113	-10.158167	
1	0.150966	0.226225	-8.795062	
2	0.119363	0.235690	-9.491795	
3	0.069641	0.189545	-8.409150	
4	0.112645	0.285203	-9.562400	
...	
182383	0.494000	0.115000	-17.321000	
182384	0.052408	0.110080	-5.643600	
182385	0.002088	0.111140	-7.618400	
182386	0.099401	0.173480	-9.415000	
182387	0.003218	0.089400	-6.303667	

	average_speechiness	average_tempo	average_valence	\
0	0.049070	121.964467	0.588167	
1	0.061812	123.069063	0.452131	
2	0.064918	123.745769	0.564369	
3	0.053715	121.415600	0.586000	
4	0.055282	120.922325	0.510517	
...	
182383	0.033400	76.492000	0.557000	
182384	0.122320	111.356200	0.454600	
182385	0.184300	107.643000	0.358000	
182386	0.124900	102.137200	0.486800	
182387	0.088600	127.145167	0.610833	

	average_track_name_length	average_daily_cost
0	22.233333	0.012134
1	22.687500	0.014780
2	19.461538	0.012399
3	21.250000	0.012706
4	24.000000	0.013076
...
182383	16.000000	0.008329
182384	11.600000	0.020058
182385	13.400000	0.018462
182386	15.000000	0.032794
182387	11.833333	0.020009

[182388 rows x 31 columns]


```
TARGET_AND_FEATURES = TARGET + FEATURES
```

Macierz korelacji cech z wartościami przewidywanymi

Posłużymy nam do wybierania cech które nie są zbyt skorelowane między sobą, a za to są skorelowane z targetem

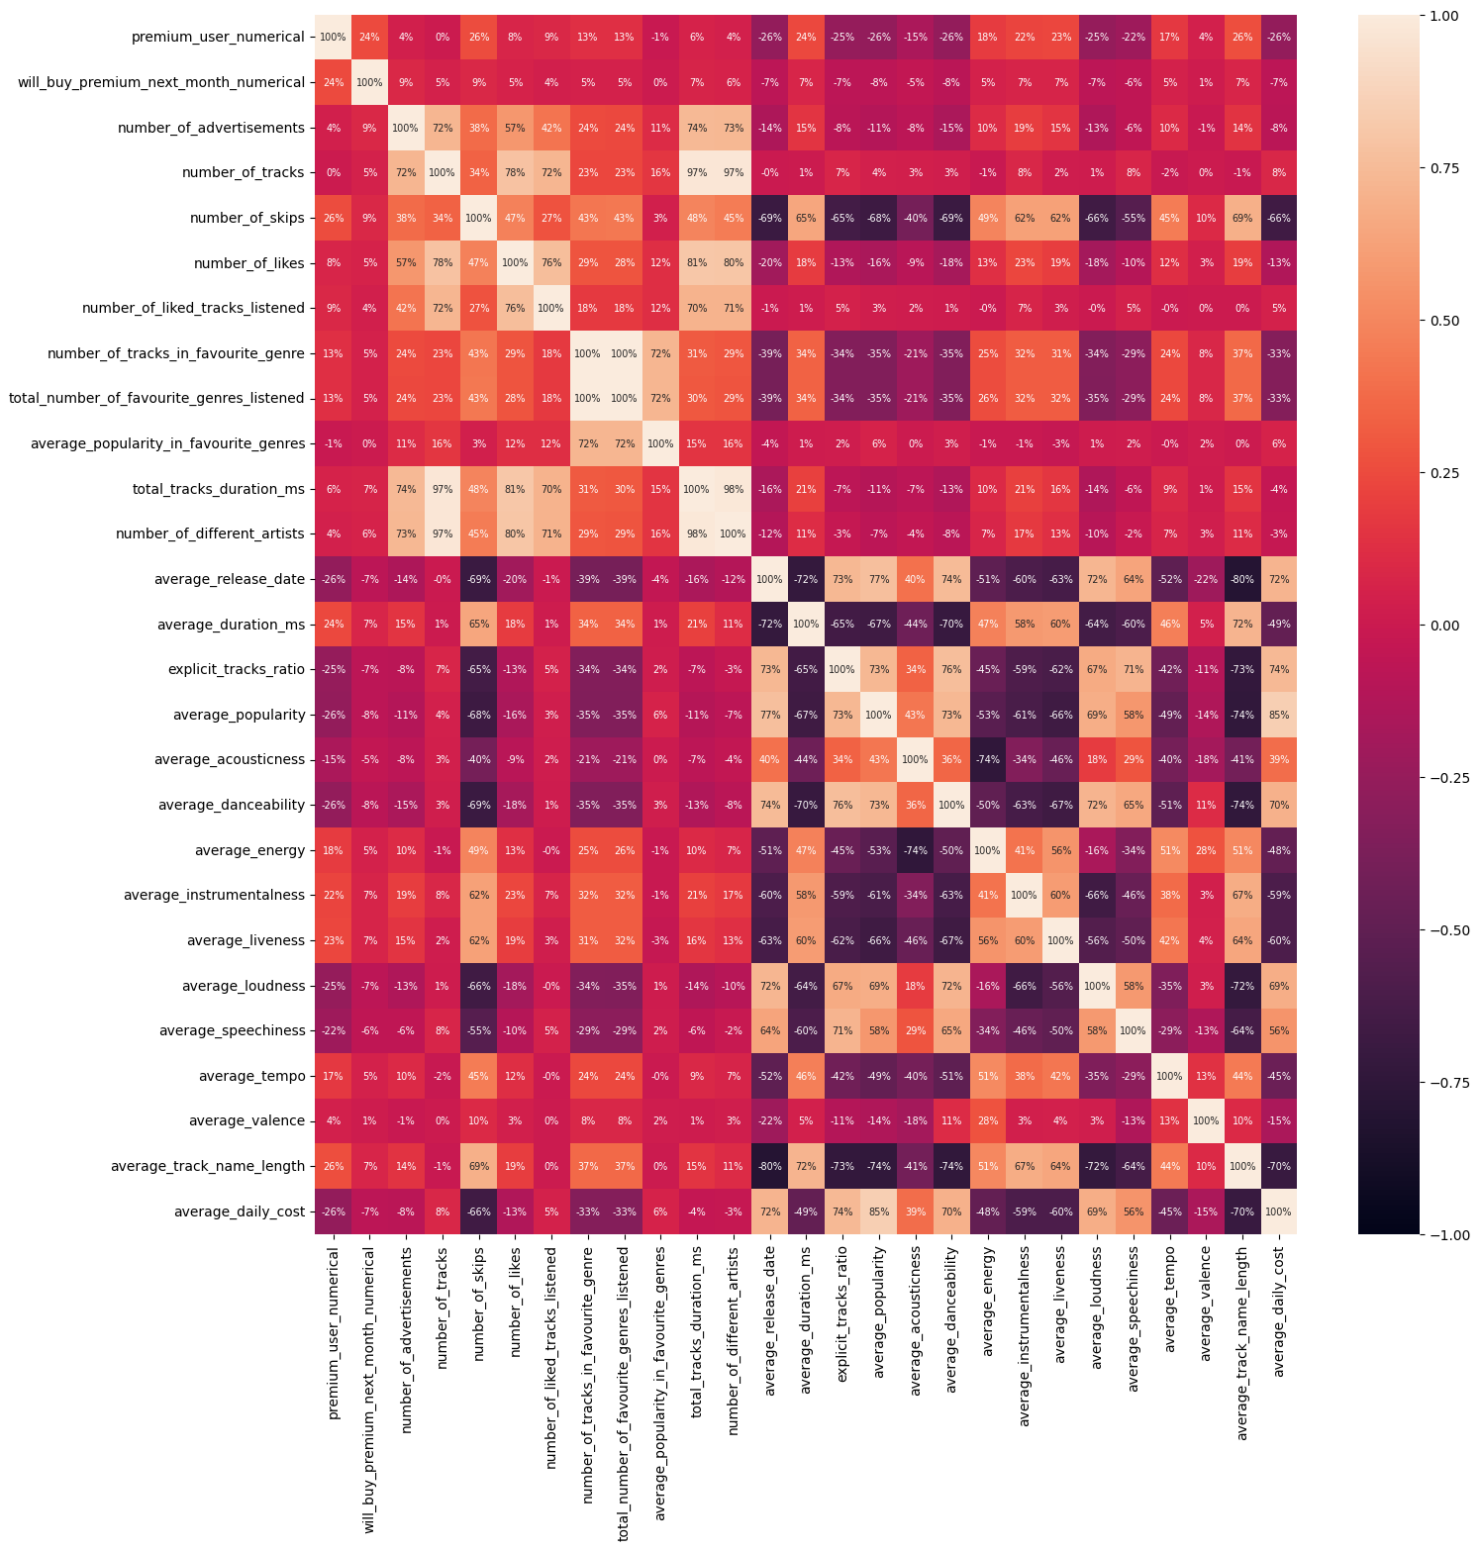
```
import seaborn as sns
from matplotlib import pyplot as plt

correlation_matrix = dataframe.loc[:, TARGET_AND_FEATURES].corr(method='spearman')

plt.figure(figsize = (16,16))

sns.heatmap(
    correlation_matrix,
    xticklabels=correlation_matrix.columns,
    yticklabels=correlation_matrix.columns,
    annot=True,
    annot_kws={"fontsize": 7},
    fmt=".0%",
    vmin=-1,
    vmax=1,
)

plt.show()
```



Przykładowy model opierający się na prostej regresji logistycznej

```

from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split

for target in TARGET:
    x_train, x_test, y_train, y_test = train_test_split(dataframe.loc[:, FEATURES], dataframe.loc[:, target], test_size=0.2, random_state=42)
    model = LogisticRegression()
    model.fit(x_train, y_train)

```

```
print(target)
display(dataframe[target].value_counts(normalize=True))
print('train_set_score = ', model.score(x_train, y_train))
print('test_set_score = ', model.score(x_test, y_test))
```

```
premium_user_numerical
```

```
0    0.740931
```

```
1    0.259069
```

```
Name: premium_user_numerical, dtype: float64
```

```
train_set_score = 0.7408571264903968
```

```
test_set_score = 0.7393543670770406
```

```
will_buy_premium_next_month_numerical
```

```
0    0.979763
```

```
1    0.020237
```

```
Name: will_buy_premium_next_month_numerical, dtype: float64
```

```
train_set_score = 0.9796561346655864
```

```
test_set_score = 0.9799631161840203
```

Posiadamy mocno niezbalansowane dane treningowe, ponieważ po agregacji ucieliśmy historię użytkowników premium w momencie zakupu usługi. Możemy to zauważyć na podstawie procentowego stosunku osób które kupią premium, a także osób które zakupią premium w przeciągu 30 dni.

Analizując wynik działania regresji liniowej możemy wywnioskować, że nasz model niczego się nie nauczył, ponieważ skuteczność na obu zbiorach jest porównywalna z naiwnym klasyfikatorem, przypisującym wszystkim rekordom wartość 0.

W kolejnym etapie postaramy się poprawić te wyniki - spróbujemy:

- dodać nowe cechy na podstawie danych
- usunąć zbędne cechy
- zbalansować / znormalizować dane
- skorzystać z innych modeli poza regresją liniową